Pronóstico Espacio-Temporal con ConvLSTM

Optimización con Algoritmo Genético · Predicción a 1 y 5 pasos

Dataset: ~1,100 imágenes · GPU: RTX 4050 (6.4 GB VRAM)

1. Preprocesamiento y Compresión de Imágenes

Dado que el hardware disponible es una RTX 4050 con 6.4 GB de VRAM, se aplicó una estrategia de compresión en tres etapas para hacer el entrenamiento viable sin perder información relevante.

Etapa	Técnica	Antes	Después
1. Resolución	Redimensionado bilineal	Original (variable)	**64 × 64 px**
2. Precisión numérica	float32 → float16	4 bytes/píxel	**2 bytes/píxel (−50%)**
3. Normalización	División entre 255	[0, 255] uint8	**[0.0, 1.0] float16**
4. Almacenamiento	NumPy .npz comprimido	Archivos individuales	**Un solo archivo (~27 MB)**

Impacto en memoria RAM

Escenario	Resolución	Precisión	Memoria (1,100 imgs)
Sin compresión (estimado)	640 × 480	float32	**~4.06 GB**
Solo reducción resolución	64 × 64	float32	~54 MB
Estrategia completa (usada)	64 × 64	float16	**~27 MB (150× menos)**

La compresión a 64×64 con float16 reduce la memoria 150× respecto al dataset sin procesar, permitiendo batch sizes de 8-16 sin saturar la VRAM de 6.4 GB.

Pipeline de ventanas temporales (Sliding Windows)

Parámetro	Valor	Descripción
seq_len	**12 frames**	Frames de entrada al encoder
pred_horizon	1 / 5 frames	Frames a predecir (según modelo)
stride	1	Máximo solapamiento entre ventanas
Split	75 / 15 / 10 %	Train / Val / Test — split temporal (sin data leakage)
Shape X	(N, 12, 64, 64, 3)	N ventanas × 12 frames × 64×64 × RGB
Shape y	(N, 5, 64, 64, 3)	N ventanas × 5 frames objetivo × 64×64 × RGB

2. Configuración del Modelo

El modelo fue optimizado mediante un Algoritmo Genético (AG) con 8 generaciones y población de 10 individuos. La configuración ganadora fue idéntica para ambas variantes del modelo.

Componente	Config 1-paso	Config Multi-paso
Arquitectura	Encoder ConvLSTM + Decoder CNN	Encoder ConvLSTM + Decoder ConvLSTM
Capas ConvLSTM	1	1
Canales ocultos	32	32
Kernel size	3×3	3×3
Dropout	0.2	0.2
seq_len	12 frames	12 frames
pred_horizon	1 frame	5 frames
Learning rate	0.005	0.005
Batch size	8	8
Parámetros	151,555	151,683
Optimizador	Adam + ReduceLROnPlateau	Adam + ReduceLROnPlateau

3. Optimización con Algoritmo Genético (AG)

Se implementó un AG para explorar automáticamente el espacio de hiperparámetros del ConvLSTM. Cada individuo representa una configuración completa del modelo y su entrenamiento. La función de fitness es el val_loss (MSE) tras entrenar 15-20 épocas — menor es mejor.

Parámetros del AG

Parámetro	Valor	Espacio de búsqueda
Tamaño de población	10	—
Generaciones	8	—
Élite	2	Los 2 mejores pasan directamente a la siguiente generación
Tasa de mutación	0.25	Prob. de cambiar cada gen aleatoriamente
Selección	Torneo k=3	Mejor de 3 individuos aleatorios
Épocas por individuo	15–20	Early stopping con paciencia = 5
n_layers	—	[1, 2, 3]
hidden_ch	—	[16, 32, 48, 64]
kernel_size	—	[3, 5]
dropout_rate	—	[0.0, 0.1, 0.2, 0.3]
seq_len	—	[5, 8, 10, 12, 15]
lr	—	[1e-4, 5e-4, 1e-3, 5e-3]
batch_size	—	[4, 8, 16]
weight_decay	—	[0.0, 1e-5, 1e-4]

Evolución del fitness por generación

Gen	Mejor fitness	Promedio fitness	Capas	Hid	Ker	seq	lr
1	0.001277	0.002849	1	16	5	8	0.005
2	0.001277	0.001487	1	16	5	8	0.005
3	0.001223	0.001486	3	16	3	12	0.005
4	0.001223	0.005107	3	16	3	12	0.005
5	0.001223	0.001294	3	16	3	12	0.005
6	0.001223	0.001729	3	16	3	12	0.005
7	0.001223	0.001534	3	16	3	12	0.005
8	0.001186	0.001459	1	32	3	12	0.005

Verde = nuevo mejor global encontrado · La generación 8 superó al candidato que dominó gen 3–7

Comparativa: candidato dominante vs configuración ganadora final

Hiperparámetro	Gen 3–7 (dominante)	Gen 8 (GANADOR)	Diferencia
val_loss (fitness)	0.001223	**0.001186**	−3.0%

n_layers	3	1	Más simple
hidden_ch	16	32	2× más canales
kernel_size	3×3	3×3	Igual
dropout_rate	0.0	0.2	+ regularización
seq_len	12	12	Igual
batch_size	4 (lento)	8 (eficiente)	2× más rápido
Parámetros	57,411	151,555	2.6× más

Conclusión del AG: una arquitectura más simple (1 capa) pero con más canales (32) y regularización (dropout=0.2) superó a la configuración profunda (3 capas) que dominó 5 generaciones consecutivas.

4. Resultados — Modelo 1-paso (t+1)

El modelo de predicción a un paso alcanzó un SSIM de 0.9729, lo que indica que las predicciones preservan el 97.3% de la similitud estructural respecto al frame real. El MSE de 0.001299 es muy bajo considerando el rango normalizado [0,1] de los píxeles.

MSE	MAE	RMSE	SSIM
0.001299	**0.006240**	**0.036045**	**0.9729**

Figura 1. Curva de pérdida — Entrenamiento final (1-paso)

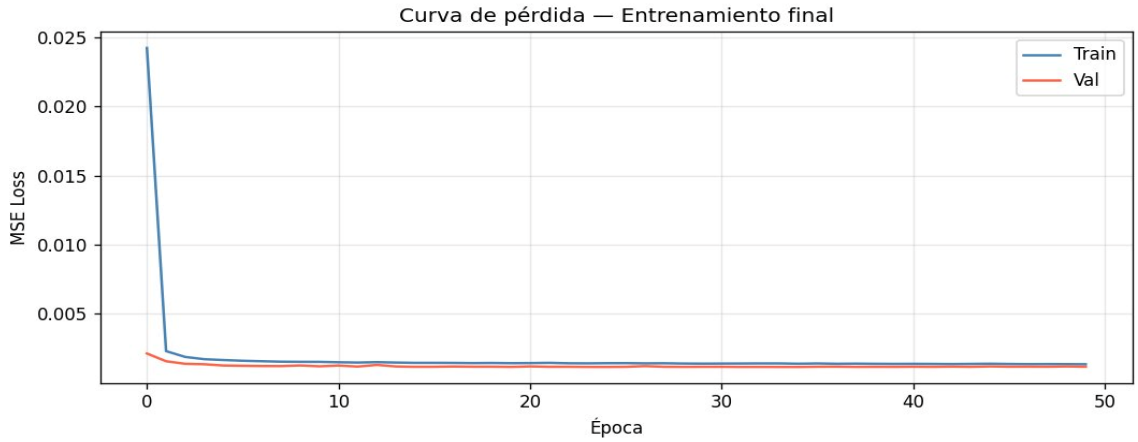

Observación: la curva de entrenamiento y validación convergen rápidamente (~5 épocas) y se mantienen muy cercanas, sin signos de sobreajuste.

Figura 2. Predicciones vs Real — Test set (1-paso)

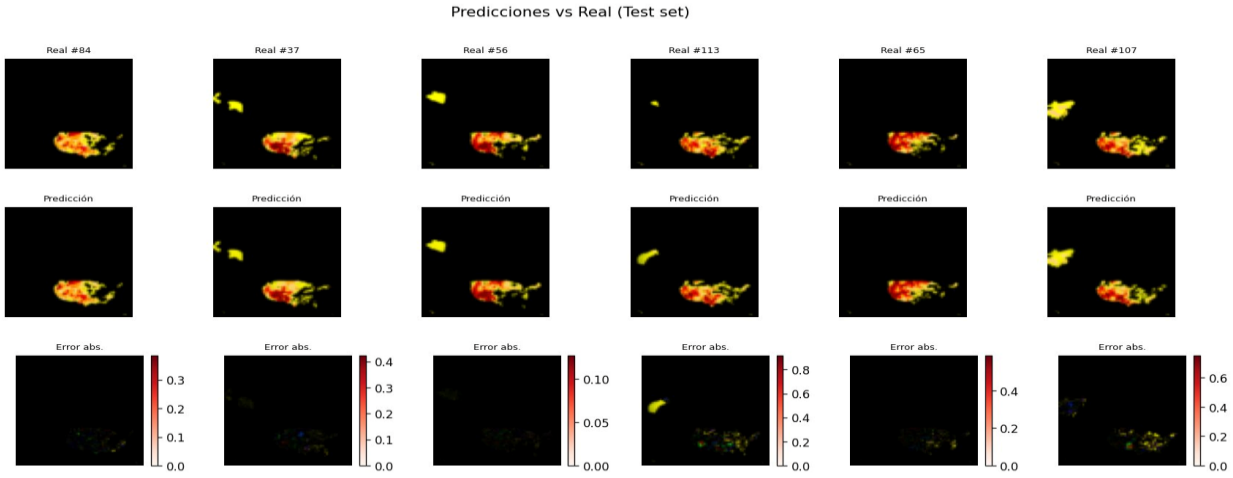

5. Resultados — Modelo Multi-step (t+1 … t+5)

El modelo Seq2Seq predice los 5 frames siguientes de forma simultánea mediante un decoder ConvLSTM autoregresivo. Las métricas se reportan por cada paso temporal y de forma global.

Paso	MSE	MAE	RMSE	SSIM	R^2
t+1	0.00356	0.01458	0.05965	0.8923	0.8525
t+2	0.00350	0.02161	0.05915	0.8953	0.8553
t+3	0.00500	0.01695	0.07073	0.8904	0.7937
t+4	0.00653	0.02031	0.08082	0.8527	0.7313
t+5	0.00787	0.02400	0.08869	0.8211	0.6772
Global	**0.005292**	0.019489	0.072743	**0.8808**	**0.7818**

Verde = bueno (MSE < 0.004, SSIM > 0.89, R^2 > 0.84) · Naranja = aceptable · Rojo = degradado

Figura 3. Curva de pérdida — Entrenamiento multi-step

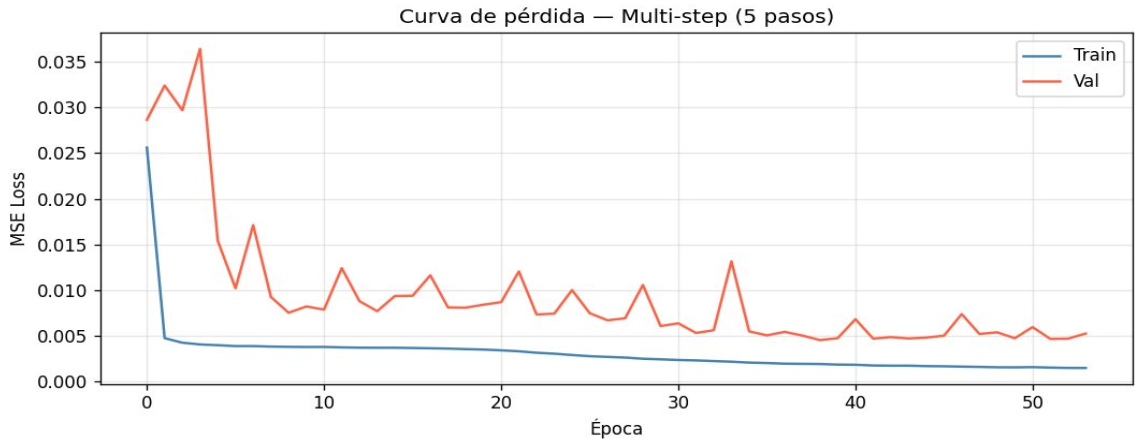

Observación: la validación muestra oscilaciones mayores que en el modelo de 1-paso, esperadas al aprender 5 horizontes simultáneamente con dataset limitado.

Figura 4. Degradación de métricas con el horizonte de predicción

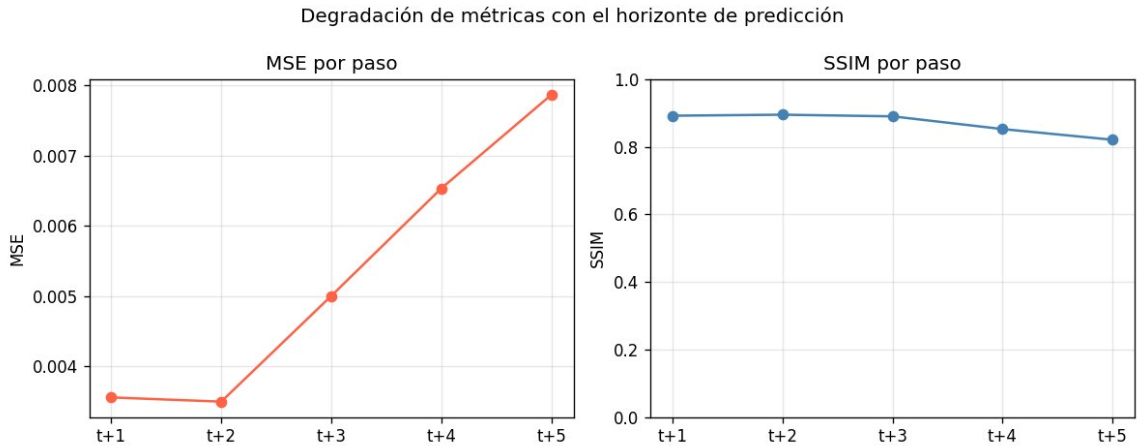

Observación: t+1 y t+2 tienen MSE casi idéntico (0.00356 vs 0.00350), la degradación se acelera a partir de t+3. El SSIM cae 8.4 puntos de t+2 a t+5.

Figura 5. Predicciones multi-step — Test set

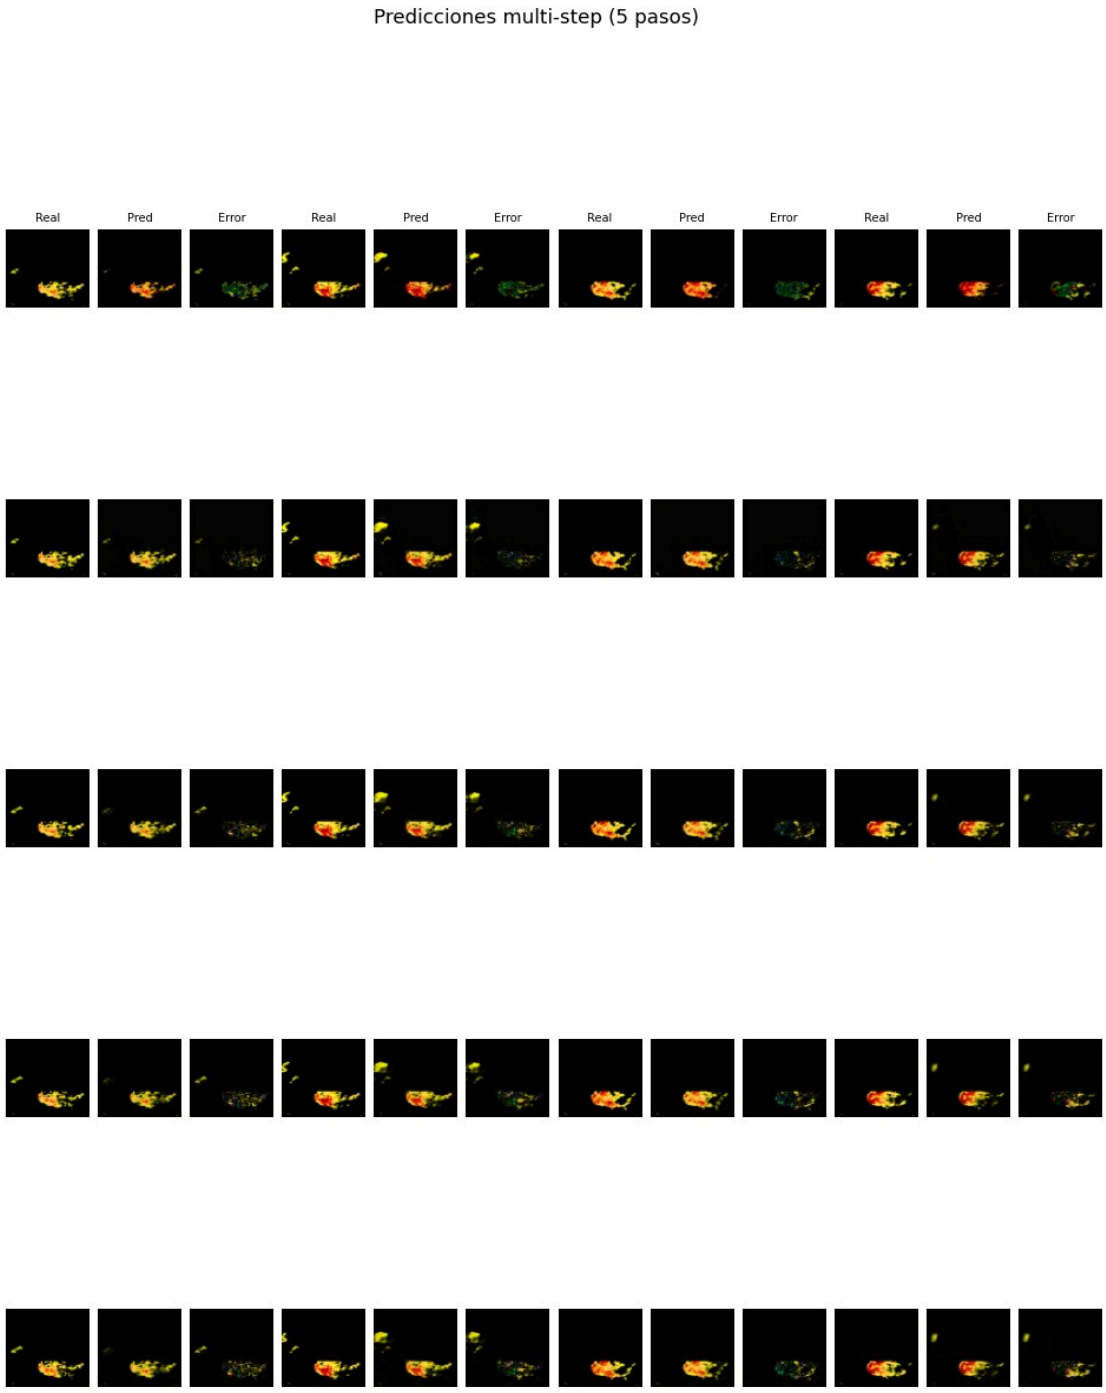

6. Comparativa 1-paso vs Multi-step

La siguiente tabla cuantifica el costo de extender el horizonte de predicción de 1 a 5 pasos. El incremento en MSE es esperable y proporcional a la complejidad de la tarea.

Métrica	1-paso	Multi-step (global)	Diferencia
MSE	0.001299	0.005292	+307%
RMSE	0.03604	0.07274	+102%
SSIM	0.9729	0.8808	-9.5 pts
R^2	—	0.7818	—

7. Discusión y Conclusiones

Fortalezas del modelo

- El modelo de 1-paso alcanza SSIM = 0.9729, resultado competitivo para pronóstico de imágenes con solo ~1,100 muestras de entrenamiento.
- La optimización con AG identificó una arquitectura ligera (151K parámetros) que supera configuraciones más complejas, evitando sobreajuste.
- Los primeros dos pasos del modelo multi-step mantienen $R^2 > 0.85$, lo que indica que la dinámica de corto plazo está bien capturada.
- El uso de mixed precision (AMP) y float16 permitió entrenar en una RTX 4050 de 6.4 GB VRAM sin restricciones de memoria.

Limitaciones y trabajo futuro

- El R^2 de t+5 (0.677) indica que el modelo pierde poder predictivo en el quinto paso. Implementar teacher forcing o loss ponderado podría mejorar los pasos lejanos.
- La validación multi-step muestra oscilaciones, sugiriendo que el dataset de ~1,100 imágenes es limitado para el horizonte de 5 pasos.
- El error se concentra visualmente en los bordes y zonas de alta intensidad de las imágenes, lo que sugiere que una pérdida perceptual (MSE + SSIM) podría mejorar la nitidez.